

TECH CHALLENGE — FASE 1

Sistema Inteligente de Suporte ao Diagnóstico

Diagnóstico de Câncer de Mama com Machine Learning

FIAP Postech — IA para Devs

Integrantes do grupo

Otaviano Montes Zibetti — RM374369 — otavianomontes@gmail.com

Felipe Squarizi — RM374950 — fesqua@yahoo.com.br

Fase: 1 — Machine Learning aplicado à Saúde da Mulher

Data de entrega: Junho de 2026

Documento de Entrega — Fase 1

Este documento reúne todos os entregáveis solicitados no Tech Challenge da Fase 1. A tarefa principal escolhida foi o **diagnóstico de câncer de mama** (classificação maligno vs. benigno) utilizando algoritmos de aprendizado de máquina sobre dados estruturados.

Links do projeto

Recurso	URL
Repositório GitHub	https://github.com/otaviano/fiap-tech-challenge-fase1
Notebook principal	https://github.com/otaviano/fiap-tech-challenge-fase1/blob/main/breast_cancer_ml.ipynb
Relatório técnico	https://github.com/otaviano/fiap-tech-challenge-fase1/blob/main/RELATORIO_TECH_CHALLENGE.md
Vídeo de demonstração	https://youtu.be/sVqwVrdWqA4
Dataset (UCI)	https://archive.ics.uci.edu/ml/datasets/Breast+Cancer+Wisconsin+%28Diagnostic%29
Dataset (Kaggle)	https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data

Conteúdo do repositório

Item exigido	Status	Onde encontrar
Código-fonte completo		<code>breast_cancer_ml.ipynb</code>
README.md com instruções de execução		README.md
Dockerfile		Dockerfile
Dataset (ou link de download)		Carregado via <code>sklearn.datasets.load_breast_cancer()</code> + links acima
Resultados (prints, gráficos e análises)		Notebook + Seções 3 a 7 deste relatório
Relatório técnico		Seções a seguir
Vídeo de demonstração (≤ 15 min)		https://youtu.be/sVqwVrdWqA4

Mapeamento das entregas técnicas exigidas

Requisito do desafio	Atendido em
Escolha do dataset e discussão do problema	Seções 1 e 2

Requisito do desafio	Atendido em
Exploração de dados (estatísticas, distribuições, padrões)	Seção 3
Pré-processamento + pipeline em Python	Seção 4
Conversão de variáveis categóricas/numéricas	Seção 4.4
Análise de correlação	Seção 3.3
Modelagem com 2+ técnicas	Seção 5 (6 algoritmos)
Separação clara treino/teste	Seção 4.2
Treinamento + avaliação (accuracy, recall, F1)	Seção 6
Justificativa da métrica escolhida	Seções 1 e 6.1
Explicabilidade (feature importance + SHAP)	Seção 7
Discussão crítica (uso prático, médico decide)	Seção 8

Relatório Técnico

1. Contexto e Problema

Um hospital universitário enfrenta crescente volume de exames e precisa de soluções de IA que acelerem a triagem e apoiem as decisões médicas. Nesta fase, o objetivo é construir a base do sistema focado em **Machine Learning** para classificação automática de resultados de exames.

Problema escolhido

Diagnóstico de câncer de mama — classificação maligno vs. benigno

O câncer de mama é o tipo de câncer mais frequente entre mulheres no Brasil e no mundo. O diagnóstico precoce é o principal fator que eleva as taxas de sobrevivência. Biópsias por agulha geram características numéricas dos núcleos celulares que podem ser analisadas por algoritmos de Machine Learning — permitindo apoio ao diagnóstico do patologista.

Por que Recall é a métrica principal?

Em diagnóstico oncológico, um **falso negativo** (classificar maligno como benigno e liberar o paciente sem tratamento) tem custo humano muito maior do que um falso positivo (acionar novas investigações em tumor benigno). Portanto, a estratégia de avaliação prioriza **maximizar o Recall da classe maligna**, mantendo Precision e F1-Score em níveis clinicamente aceitáveis.

2. Dataset

Nome: Wisconsin Breast Cancer Diagnostic Dataset (WBCD)

Fonte original: UCI Machine Learning Repository

Disponível via: `sklearn.datasets.load_breast_cancer()`

Características gerais

Atributo	Valor
Total de amostras	569
Features numéricas	30
Classes	2 (Maligno / Benigno)
Valores nulos	0 (nenhum)

Atributo	Valor
Distribuição	Maligno: 212 (37,3%) / Benigno: 357 (62,7%)

Origem das features

Cada tumor foi digitalmente fotografado e, a partir da imagem, foram calculadas 10 características dos núcleos celulares:

Característica	Descrição
radius	Média das distâncias do centro à periferia
texture	Desvio padrão dos valores de escala de cinza
perimeter	Perímetro do núcleo
area	Área do núcleo
smoothness	Variação local nos comprimentos dos raios
compactness	$(\text{perímetro}^2 / \text{área}) - 1,0$
concavity	Gravidade das porções côncavas do contorno
concave points	Número de porções côncavas do contorno
symmetry	Simetria do núcleo
fractal dimension	"Aproximação da linha de costa" - 1

Cada uma das 10 características é representada em **3 versões**: média (mean), erro padrão (error) e pior valor (worst) — totalizando **30 features**.

3. Exploração dos Dados (EDA)

3.1 Distribuição das classes

O dataset apresenta **leve desbalanceamento** (37% maligno / 63% benigno), que foi tratado com split estratificado para garantir proporções equivalentes em treino e teste.

```

Maligno (0): 212 amostras - 37,3%
Benigno (1): 357 amostras - 62,7%
```




Figura 1 — Distribuição das classes (Maligno x Benigno)

3.2 Estatísticas descritivas (features mean)

As features de raio, perímetro e área apresentam grande variação de escala (ex.: `mean area` varia de 143 a 2.501 mm²) em relação a features como `mean smoothness` (0,05 a 0,16). Isso justifica o uso de **StandardScaler** antes de modelos sensíveis a escala (SVM, KNN, Regressão Logística).




Figura 2 — Distribuição das features (mean) por classe

3.3 Análise de correlação

As features mais correlacionadas com o target (correlação absoluta) foram:

Rank	Feature	Correlação absoluta com target
1	worst concave points	0,794
2	worst perimeter	0,783
3	mean concave points	0,777
4	worst radius	0,776
5	mean perimeter	0,743

Features do grupo `worst` (pior valor observado) têm maior poder discriminativo que as médias — indicando que o comportamento no pior caso é mais diagnóstico que a tendência central.

Multicolinearidade observada: features de raio, perímetro e área são altamente correlacionadas entre si ($r > 0,95$), o que é esperado geometricamente. Isso não prejudica modelos baseados em árvores (Random Forest, Gradient Boosting), mas pode afetar a interpretabilidade de modelos lineares.




Figura 3 — Mapa de correlação entre as features 'mean'




Figura 4 — Ranking de correlação das features com o diagnóstico

4. Pré-processamento

4.1 Pipeline de pré-processamento

O pré-processamento foi encapsulado em `sklearn.Pipeline`, garantindo que transformações sejam aplicadas corretamente dentro do cross-validation (sem data leakage):

```
Pipeline([
    ('scaler', StandardScaler()),
    ('model', <algoritmo>)
])
```

4.2 Divisão treino/teste

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,      # 80% treino, 20% teste
```

```
random_state=42,
stratify=y          # mantém proporção das classes
)
```

Conjunto	Amostras	Maligno	Benigno
Treino	455	170	285
Teste	114	42	72

4.3 Normalização

`StandardScaler` foi aplicado apenas às features (nunca ao target), com `fit` exclusivo no conjunto de treino e `transform` aplicado ao teste — evitando vazamento de informação:

```
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train) # fit + transform
X_test_scaled = scaler.transform(X_test)      # apenas transform
```

Antes do scaling: mean area varia de 143 a 2501 (escala grande)

Após o scaling: todas as features centradas em 0 com desvio padrão ≈ 1




Figura 5 — Efeito do StandardScaler (antes x depois)

4.4 Variáveis categóricas

O dataset não contém variáveis categóricas — todas as 30 features são numéricas contínuas. Nenhuma codificação (one-hot, label encoding) foi necessária.

4.5 Valores ausentes

Nenhum valor nulo encontrado no dataset.

5. Modelagem

5.1 Modelos selecionados

Foram treinados e comparados **6 algoritmos de classificação**:

Modelo	Justificativa
Logistic Regression	Baseline linear; interpretável e eficiente; bom ponto de partida para problemas de classificação binária
Decision Tree	Modelo explicável (regras de decisão); útil para entender o problema, mesmo que não seja o mais preciso
Random Forest	Ensemble que reduz overfitting via bagging; robusto e com feature importance nativa; escolhido para SHAP
Gradient Boosting	Ensemble sequencial com alto poder preditivo; bom em datasets tabulares estruturados
SVM	Alta performance em espaços de alta dimensão; robusto a outliers; selecionado como modelo final por melhor Recall
KNN	Modelo baseado em distância; simples e sem suposições paramétricas; útil como comparativo

5.2 Validação cruzada

Foi utilizada **StratifiedKFold com 5 folds** para garantir: - Avaliação robusta sem overfitting ao conjunto de teste - Manutenção da proporção das classes em cada fold - Estimativas de variância nos resultados (desvio padrão)

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

6. Treinamento e Avaliação

6.1 Resultados do Cross-Validation (5-Fold)

Recall e F1-Score referem-se à **classe MALIGNA (pos_label=0)** — o erro crítico a minimizar.

Modelo	Recall Maligno	F1 Maligno	Accuracy	AUC
SVM	0,958 ± 0,037	0,969	0,977	0,995
Logistic Regression	0,944 ± 0,052	0,963	0,974	0,995
Random Forest	0,939 ± 0,050	0,941	0,956	0,989

Modelo	Recall Maligno	F1 Maligno	Accuracy	AUC
KNN	0,925 ± 0,046	0,949	0,963	0,985
Gradient Boosting	0,906 ± 0,066	0,929	0,949	0,993
Decision Tree	0,878 ± 0,082	0,899	0,928	0,907

Modelo selecionado: SVM — maior Recall médio (0,958) e menor variância ($\pm 0,037$), indicando estabilidade e confiabilidade.




Figura 6 — Comparação de desempenho dos 6 modelos

6.2 Avaliação do SVM no Test Set

Classification Report — SVM

	precision	recall	f1-score	support
Maligno	0.98	0.98	0.98	42
Benigno	0.99	0.99	0.99	72
accuracy			0.98	114
macro avg	0.98	0.98	0.98	114
weighted avg	0.98	0.98	0.98	114

6.3 Matriz de Confusão (SVM — Test Set)

		Predito		
		Maligno	Benigno	
Real	Maligno	41	1	← 1 Falso Negativo (crítico)
	Benigno	1	71	← 1 Falso Positivo

Métrica no Test Set	Valor
Accuracy	98,25%
Recall (Maligno)	97,62%
Precision (Maligno)	97,62%
F1-Score (Maligno)	97,62%

Métrica no Test Set	Valor
AUC-ROC	0,9950
Falsos Negativos	1
Falsos Positivos	1

1 falso negativo em 42 casos malignos = 97,6% de sensibilidade — clinicamente expressivo como ferramenta de triagem.




Figura 7 — Matriz de confusão do SVM no test set

6.4 Curva ROC

O SVM atingiu **AUC = 0,9950**, próximo de 1,0 (classificação perfeita). A curva ROC demonstra que o modelo é capaz de discriminar tumores malignos de benignos em quase todos os pontos de corte de probabilidade.

Ranking AUC no test set: 1. SVM: 0,9950 2. Logistic Regression: ~0,995 3. Gradient Boosting: ~0,993 4. Random Forest: 0,9937 5. KNN: ~0,985 6. Decision Tree: ~0,907




Figura 8 — Curva ROC do SVM (AUC = 0,995)




Figura 9 — Curvas ROC sobrepostas de todos os modelos

7. Explicabilidade com SHAP

Para garantir a interpretabilidade clínica, foi aplicado **SHAP (SHapley Additive exPlanations)** usando o `TreeExplainer` sobre o **Random Forest** (modelos tree-based são mais eficientes com SHAP).

SHAP quantifica a contribuição marginal de cada feature para cada predição individual, baseado na teoria de valores de Shapley de jogos cooperativos.

7.1 Importância Global das Features (Top 10)

Rank	Feature	Importância média (mean abs SHAP)
1	worst area	0,312
2	worst concave points	0,298
3	worst radius	0,241
4	mean concave points	0,198

Rank	Feature	Importância média (mean abs SHAP)
5	worst perimeter	0,187
6	mean area	0,145
7	worst concavity	0,132
8	mean radius	0,121
9	mean perimeter	0,118
10	area error	0,089




Figura 10 — Importância global das features (SHAP summary)




Figura 11 — Feature importance: Random Forest nativo x SHAP

7.2 Interpretação Clínica

O SHAP Beeswarm plot revela a **direção** do impacto de cada feature:

- **Valores altos de** `worst area` (vermelho) → empurram a predição para **Maligno**
- **Valores baixos de** `worst concave points` (azul) → empurram para **Benigno**
- Features do grupo `worst` consistentemente dominam — confirmando que o comportamento no pior núcleo celular é mais informativo que as médias




Figura 12 — SHAP beeswarm: direção do impacto de cada feature

7.3 Convergência SHAP vs. Feature Importance nativa

Tanto o SHAP quanto o feature importance nativo do Random Forest concordam nas features mais relevantes (`worst area` , `worst concave points` , `worst radius`), o que aumenta a confiança na interpretação. A diferença é que o SHAP revela **direção e magnitude por amostra**, enquanto o importance nativo fornece apenas uma importância global agregada.

7.4 Explicação individual (Force Plot)

Para a primeira amostra do test set (Maligno, classificado corretamente como Maligno): - Probabilidade de benigno: 0,000 (máxima confiança) - Features que mais contribuíram para Maligno: `worst area` alto, `worst concave points` alto, `worst radius` alto




Figura 13 — SHAP force plot de uma predição individual

8. Discussão Crítica

8.1 O modelo pode ser utilizado na prática?

Sim, como ferramenta de apoio à decisão — não como substituto ao médico.

Com **97,6% de Recall** (sensibilidade) e **AUC 0,995**, o modelo tem performance comparável a sistemas de CAD (Computer-Aided Detection) relatados na literatura. Resultados semelhantes são encontrados em artigos publicados utilizando o mesmo dataset (UCI Wisconsin).

8.2 Como integrá-lo clinicamente?

Cenário recomendado — triagem assistida:

1. Patologista realiza biópsia por agulha → sistema extrai as 30 características celulares
2. Modelo classifica o tumor como provável maligno/benigno com probabilidade associada
3. **Casos de alta probabilidade maligna → prioridade na fila de análise do médico**
4. **Médico sempre tem a palavra final** — o modelo é um alerta, não um diagnóstico

8.3 Limitações

Limitação	Impacto	Mitigação
Dataset pequeno (569 amostras)	Risco de resultados inflados	Validar em datasets maiores e multicêntricos
Dados de único centro (Wisconsin, 1995)	Viés demográfico e temporal	Retreinar com dados contemporâneos e diversificados
Features extraídas manualmente de imagens digitalizadas	Dependência de software de análise de imagem	Integrar com pipeline de visão computacional
Sem validação prospectiva	Performance em dados do mundo real pode diferir	Estudo piloto hospitalar necessário
Desbalanceamento leve	Pode subestimar Recall em produção	Investigar SMOTE e threshold tuning

8.4 Próximos passos técnicos

Técnica	Benefício esperado
GridSearchCV para SVM (C, gamma, kernel)	Otimização de hiperparâmetros
Threshold tuning (ex.: 0,3 em vez de 0,5)	Aumentar Recall à custa de Precision
SMOTE	Balancear classes para reduzir viés
PCA para visualização	Entender a separabilidade das classes em 2D
Ensemble SVM + LR	Combinar os dois melhores modelos
MLflow	Rastreamento de experimentos e versionamento
FastAPI + Docker	Deploy como microserviço hospitalar

8.5 Aspectos éticos

O uso de IA em diagnóstico médico exige: - **Transparência:** o modelo deve ser explicável ao médico (SHAP atende a isso) - **Responsabilidade:** falsos negativos podem ter consequências legais — documentar limitações - **Consentimento:** pacientes devem ser informados do uso de IA na análise de seus exames - **Supervisão contínua:** monitorar drift de performance ao longo do tempo

9. Instruções de Execução

9.1 Requisitos

- Python 3.11+
- pip ou conda

9.2 Instalação local

```
# Clonar o repositório
git clone https://github.com/otaviano/fiap-tech-challenge-fase1.git
cd fiap-tech-challenge-fase1

# Criar ambiente virtual
python -m venv .venv
source .venv/bin/activate      # Linux/Mac
.venv\Scripts\activate        # Windows

# Instalar dependências
pip install -r requirements.txt

# Executar o notebook
jupyter notebook breast_cancer_ml.ipynb
```

9.3 requirements.txt

```
scikit-learn>=1.3.0
pandas>=2.0.0
numpy>=1.24.0
matplotlib>=3.7.0
seaborn>=0.12.0
shap>=0.43.0
jupyter>=1.0.0
ipykernel>=6.0.0
```

9.4 Execução via Docker

```
# Build
docker build -t breast-cancer-ml .

# Executar (Jupyter Lab na porta 8888)
docker run -p 8888:8888 breast-cancer-ml
```

Acesse `http://localhost:8888` no navegador.

9.5 Sobre o dataset

O dataset **Wisconsin Breast Cancer** é carregado automaticamente via

`sklearn.datasets.load_breast_cancer()` — **não é necessário fazer download manual**.
Ele está embutido na biblioteca scikit-learn.

Para referência, os mesmos dados estão disponíveis em: - [UCI ML Repository](#) - [Kaggle](#)

Tech Challenge Fase 1 — FIAP Postech IA para Devs — Junho de 2026